

Projet
Machine Learning - HAI817I

Classification de tweets scientifiques (SciTweets)

Groupe 13

BASILE Francesco-Pio (22211051)

REY Dorian (22205790)

BOUREUX Nathan (22206444)

Master 1 informatique, parcours génie logiciel

2025-2026



Table des matières

1	Introduction	1
2	Architecture et pipeline	1
3	Résultats — Tâche 1 : SCI vs NON-SCI	2
4	Résultats — Tâche 2 : {CLAIM, REF} vs {CONTEXT}	3
5	Résultats — Tâche 3 : {CLAIM} × {REF} × {CONTEXT} (multi-label)	3
6	Features discriminantes (Bonus)	5
7	Conclusion	5

1 Introduction

Ce projet porte sur la classification automatique de tweets issus du dataset SciTweets [1] selon leur rapport à la science, sur trois tâches de complexité croissante : (T1) SCI vs NON-SCI sur l'ensemble du corpus, (T2) {CLAIM, REF} vs {CONTEXT} sur les seuls tweets SCI, et (T3) classification multi-label {CLAIM} $\times$ {REF} $\times$ {CONTEXT} sur les tweets SCI.

Pour mener cette étude, nous avons utilisé deux approches complémentaires. La première, appelée **baseline**, consiste à tester manuellement plusieurs classifieurs (Naive Bayes, SVM, Random Forest, KNN, Decision Tree) avec un prétraitement TF-IDF et des classifieurs aux hyperparamètres par défaut. Cette approche nous a permis de comprendre l'effet de chaque étape (nettoyage, équilibrage, vectorisation) sur les performances. La seconde, basée sur **Optuna**, optimise automatiquement à la fois les paramètres du vectoriseur, la stratégie de rééchantillonnage et le choix du classifieur avec ses hyperparamètres. Elle nous donne des résultats reproductibles et évite les biais d'évaluation rencontrés avec l'approche manuelle.

Usage des outils d'IA. Claude a été utilisé à des fins d'assistance technique : débogage de code, correction de bugs dans le pipeline Optuna, génération de code pour les visualisations, conseil sur quoi faire en général, relecture du texte du rapport.

2 Architecture et pipeline

Le pipeline repose sur trois étapes enchaînées dans un `ImbPipeline` [2] : nettoyage du texte, vectorisation et classification. L'ensemble des choix est automatisé par Optuna [3] sur 150 trials par tâche avec évaluation par validation croisée 5-folds (F1 macro), **sans aucune fuite de données** : le vectoriseur et le rééchantillonneur sont re-fittés à l'intérieur de chaque fold.

TABLE 1 – Espace de recherche Optuna

Étape	Options explorées
Prétraitement	minuscules, suppression URLs/mentions/HTML, expansion des contractions anglaises
Vectorisation	CountVectorizer ou TF-IDF, ngram (1,1)/(1,2)/(1,3), min_df $\in$ [1, 10], max_df $\in$ [0.5, 0.95]
Classifieur	LR, LinearSVM, RF, NB, KNN, DT + hyperparamètres spécifiques à chaque modèle
Déséquilibre	aucun / RandomOverSampler / RandomUnderSampler

Justification des choix. La gestion du déséquilibre via le sampler est intégrée dans le pipeline et explorée par Optuna plutôt que fixée a priori, car son effet varie selon la tâche et le modèle. Pour T3, le rééchantillonnage multi-label est réalisé colonne par colonne (`resample_multilabel`) car imbalanced-learn ne supporte pas nativement les cibles matricielles.

Un point notable sur T2 : la distribution est très déséquilibrée (342 CLAIM+REF contre 33 CONTEXT, ratio 10 :1), ce qui rend la tâche structurellement difficile indépendamment du classifieur choisi.

3 Résultats — Tâche 1 : SCI vs NON-SCI

Le meilleur modèle sélectionné par Optuna est **LogReg** avec un F1 macro (CV) de **0.769**, obtenu avec : CountVectorizer, ngram (1,1), min_df=4, oversampling, $C = 0.46$.

TABLE 2 – Résultats baseline et Optuna — Tâche 1

Modèle	Accuracy	F1 macro	Précision	Rappel
Naive Bayes	0.809	0.786	0.785	0.791
SVM	0.809	0.770	0.795	0.760
Random Forest	0.776	0.718	0.772	0.717
Decision Tree	0.732	0.705	0.703	0.714
KNN	0.693	0.678	0.685	0.704
Optuna (LogReg)	—	0.769	—	—
Baseline (NB)	—	0.786	—	—
Écart		−0.017		

La matrice de confusion du meilleur modèle Optuna (LogReg, test set $n = 228$) montre 137 vrais NON-SCI, 55 vrais SCI, 16 faux positifs SCI et 20 faux négatifs SCI. La baseline Naive Bayes donne 133/54 vrais, 20/21 erreurs.

Analyse et recul

Optuna sélectionne LogReg (F1 0.769) mais la baseline Naive Bayes obtient 0.786 : l'écart s'explique par une **fuite de données dans la baseline**. Le vectoriseur de la baseline est fitté sur les 1140 tweets avant le split, incorporant indirectement les statistiques du test set. Optuna, lui, re-vectorise à l'intérieur de chaque fold, ses scores sont donc honnêtes.

En pratique, les deux approches convergent vers LogReg ou NB avec TF-IDF, ce qui est cohérent avec la littérature sur la classification de texte sparse : les modèles linéaires dominent. L'hyperparamètre le plus important selon Optuna est le choix du classifieur (importance 0.65), suivi de max_df (0.26) ; le type de vectoriseur et le sampler ont un effet marginal, ce qui indique que le **signal lexical est suffisamment fort** sur T1 pour être robuste à ces choix.

KNN est le moins performant (F1 0.678), attendu sur des données TF-IDF sparse à haute dimension.

4 Résultats — Tâche 2 : {CLAIM, REF} vs {CONTEXT}

Le meilleur modèle sélectionné par Optuna est **DT** avec un F1 macro (CV) de **0.653**, obtenu avec : CountVectorizer, ngram (1,2), oversampling, max_df = 0.64.

TABLE 3 – Résultats baseline et Optuna — Tâche 2

Modèle	Accuracy	F1 macro	Précision	Rappel
SVM	0.925	0.704	0.801	0.668
KNN	0.816	0.622	0.609	0.713
Naive Bayes	0.797	0.611	0.603	0.695
Decision Tree	0.829	0.569	0.565	0.613
Random Forest	0.917	0.528	0.658	0.529
Optuna (DT)	—	0.653	—	—
Baseline (SVM)	—	0.704	—	—
Écart		−0.051		

La matrice de confusion (test set $n = 75$) du meilleur modèle Optuna DT montre 68 CLAIM+REF bien classés, 5 CLAIM+REF mal classés, 5 CONTEXT bien classés, 2 CONTEXT mal classés. La baseline SVM obtient 66/2 et 3/4.

Analyse et recul

T2 est la tâche la plus difficile de ce projet malgré son apparence binaire. La cause principale est le **déséquilibre extrême** : 342 CLAIM+REF contre 33 CONTEXT (ratio 10 :1). Tout modèle a tendance à prédire CLAIM+REF par défaut et à sacrifier le rappel sur CONTEXT.

Optuna sélectionne DT avec oversampling (F1 0.653), inférieur à la baseline SVM (0.704). Deux raisons : (1) DT sur-ajuste facilement avec oversampling sur un corpus de 375 tweets ; (2) le graphe d'importance Optuna montre que le **sampler est l'hyperparamètre le plus important** (importance 0.56) et le classifieur second (0.40), ce qui signifie que la stratégie d'équilibrage prime sur le modèle lui-même. SVM gère mieux le déséquilibre car la marge de séparation est robuste aux exemples dupliqués.

L'accuracy élevée (0.925 pour SVM) est trompeuse : elle reflète la domination de CLAIM+REF. Le F1 macro, qui donne le même poids aux deux classes, révèle la vraie difficulté.

5 Résultats — Tâche 3 : {CLAIM} × {REF} × {CONTEXT} (multi-label)

Justification de l'approche multi-label. L'analyse empirique du dataset révèle que 58% des tweets SCI ont plusieurs labels à 1 simultanément (voir Table 4). Forcer un seul label par tweet (approche mono-label avec priorité) ferait perdre le signal de plus de la moitié des données. On entraîne donc 3 classifieurs binaires indépendants via `OneVsRestClassifier`, comme dans l'article SciTweets original.

TABLE 4 – Combinaisons de labels observées dans les 375 tweets SCI

Combinaison	Nb tweets	% SCI
CLAIM seul	124	33%
CLAIM+REF+CONTEXT	124	33%
REF+CONTEXT	79	21%
CONTEXT seul	33	9%
CLAIM+CONTEXT	15	4%

Résultats. Le meilleur modèle Optuna est **Random Forest** avec un F1 macro (CV) de **0.825**, obtenu avec : TF-IDF, ngram (1,2), min_df=3, sans sampler, $n_estimators = 186$, max_depth=48.

TABLE 5 – Résultats baseline et Optuna — Tâche 3

Modèle	Accuracy	F1 macro	Hamming loss	Subset acc.
Random Forest	0.753	0.821	0.247	0.480
SVM	0.749	0.805	0.251	0.472
LogReg	0.700	0.794	0.300	0.331
Naive Bayes	0.688	0.789	0.312	0.339
Decision Tree	0.710	0.776	0.290	0.408
KNN	0.667	0.754	0.333	0.397
Optuna (RF)	—	0.825	—	—
Baseline (RF)	—	0.821	—	—
Écart		+0.004		

TABLE 6 – Métriques par label — Tâche 3 (meilleur modèle Optuna)

Label	Précision	Rappel	F1	Support
CLAIM	0.79	0.92	0.85	263
REF	0.68	0.91	0.78	203
CONTEXT	0.79	0.93	0.85	251
Macro avg	0.75	0.92	0.83	717
<i>Hamming loss : 0.242 Subset accuracy (exact match) : 0.493</i>				

Rapport de classification (test set, CV 5-folds).

Analyse et recul

T3 est la tâche la plus difficile structurellement. Trois observations majeures :

(1) Random Forest domine, contrairement à T1 où LR/NB suffisait. Sur un problème multi-label avec des labels corrélés (58% des tweets ont plusieurs labels), RF capture mieux les interactions entre features. L'écart baseline / Optuna est quasi nul (+0.004) : la baseline RF était déjà proche du plafond atteignable avec cette représentation.

(2) Recall très élevé (0.91–0.93) mais précision modérée (0.68–0.79). Le modèle sur-prédit les labels positifs, ce qui s'explique par la forte prévalence de chaque label (CLAIM 70%, REF 54%, CONTEXT 67%) : prédire "positif" est une stratégie rentable en recall. La précision de REF (0.68) est la plus faible : ce label est le plus rare et le plus difficile à distinguer des autres car il co-apparaît toujours avec CONTEXT.

(3) Subset accuracy de 0.493 : environ la moitié des tweets ont les 3 labels exactement bien prédits. C’est cohérent avec la difficulté de la tâche et le fait que l’approche “3 binaires indépendants” ignore les corrélations entre labels (ex : REF implique presque toujours CONTEXT).

L’importance des hyperparamètres Optuna (sampler 0.53, clf 0.36) confirme que la stratégie d’équilibrage est le levier le plus puissant, même si Optuna choisit finalement “none” : avec des labels majoritaires, l’oversampling n’apporte pas de gain.

6 Features discriminantes (Bonus)

Les features sont extraites via une LogReg sur TF-IDF (1,2)-grammes, coefficients par classe (OneVsRest pour T3).

Tâche 1 — Séparation lexicale nette. Les features SCI sont des termes médicaux et scientifiques (**research**, **study**, **cancer**, **health**, **climate**, **risk**). Deux marqueurs de style académique ressortent : **of** et **in**, porteurs de constructions comme “*increase of risk*” ou “*study in*”. Les features NON-SCI (**stop**, **support**, **please**, **trump**, **need**) sont des mots d’appel à l’action et d’opinion politique, cohérents avec des tweets militants. Cette séparation si nette explique à la fois les bonnes performances et le faible impact des prétraitements sur T1.

Tâche 2 — Signal de style d’énonciation. CLAIM+REF se distingue par des verbes d’assertion et de causalité (**increase**, **leads to**, **can**, **is**, **are**), tandis que CONTEXT mobilise peu de features distinctives fortes. Le déséquilibre 10 :1 explique que le modèle apprend surtout les marqueurs de CLAIM+REF.

Tâche 3 — Chevauchement entre classes. CLAIM se distingue par des verbes de causalité (**cause**, **leads to**, **increase**) et des déterminants de généralisation (**people**, **men**, **women**). REF partage beaucoup de features avec CONTEXT (**eurekamag**, **research**, **scientists**), ce qui explique sa précision inférieure (0.68). CONTEXT a les features les plus dispersées car il co-apparaît avec les deux autres labels.

Comparaison inter-tâches. L’intersection des tops-features entre T1 et T3 est faible : T1 discrimine “science vs non-science” via le *vocabulaire de domaine*, tandis que T3 discrimine le *type de discours scientifique* via le vocabulaire de style (verbes d’assertion, marqueurs bibliographiques). Cette différence explique pourquoi les prétraitements (stopwords, lemmatisation) ont un impact sur T1 mais quasi nul sur T3 : en T3, même les mots fonctionnels portent du signal de style.

7 Conclusion

Ce projet a permis d’obtenir un F1 macro de **0.769** sur T1 (LogReg, Optuna), **0.653** sur T2 (DT, Optuna) et **0.825** sur T3 (RF, Optuna).

La progression de T1 vers T3 illustre trois niveaux de difficulté distincts. Sur T1, TF-IDF + modèle linéaire suffit grâce à un signal lexical de domaine très fort ; les prétraitements n’ont qu’un impact marginal. Sur T2, le déséquilibre extrême (10 :1) est le facteur limitant dominant, pas le modèle : le sampler devient l’hyperparamètre le plus important selon Optuna. Sur T3, la limite est avant tout structurelle : les labels sont fortement corrélés et les frontières sémantiques entre CLAIM, REF et CONTEXT sont trop fines pour TF-IDF. L’approche “3 binaires indépendants” ignore ces corrélations.

Références

- [1] Hafid, S., Schellhammer, S., Bringay, S., Todorov, K., & Dietze, S. (2022). SciTweets — A Dataset and Annotation Framework for Detecting Scientific Online Discourse. *Proceedings of the 31st ACM CIKM*, pp. 3988–3992.
- [2] Lemaître, G., Nogueira, F., & Aridas, C.K. (2017). Imbalanced-learn : A Python Toolbox to Tackle the Curse of Imbalanced Datasets. *JMLR*, 18(17), 1–5.
- [3] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna : A Next-generation Hyperparameter Optimization Framework. *arXiv :1907.10902*.
- [4] Nguyen, D.Q., Vu, T., & Nguyen, A.T. (2020). BERTweet : A Pre-trained Language Model for English Tweets. *EMNLP : System Demonstrations*, pp. 9–14.